



Πανεπιστήμιο Αιγαίου
Τμήμα Μηχανικών Πληροφοριακών και Επικοινωνιακών
Συστημάτων

321-6600 – Προηγμένη Ρομποτική

Διδάσκων: Μάριος Βασιλείου

Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 ΓΡΗΓΟΡΙΔΟΥ ΑΘΑΝΑΣΙΑ

Σάμος, 15 Ιουνίου, 2024



Περίληψη

Η εργασία εστιάζει στον τρόπο ανίχνευσης και διαχείρισης των ασθενειών που επηρεάζουν τα φυτά στην Ελλάδα, χρησιμοποιώντας προηγμένες τεχνολογίες. Η γεωργία στην Ελλάδα αντιμετωπίζει σοβαρές προκλήσεις λόγω αυτών των ασθενειών και των παρασίτων, οι οποίοι μπορούν να προκαλέσουν σημαντικές απώλειες στις σοδειές και στα κέρδη των αγροτών. Οι παραδοσιακές μέθοδοι εντοπισμού ασθενειών ενδέχεται να μην είναι επαρκείς ή να απαιτούν υψηλό επίπεδο εξειδίκευσης.

Στο πλαίσιο αυτό, προτείνουμε ένα μοντέλο που βασίζεται σε αλγορίθμους μηχανικής μάθησης για να υποστηρίξει τους αγρότες στον ακριβή εντοπισμό και την αποτελεσματική αντιμετώπιση των ασθενειών των φυτών. Χρησιμοποιήθηκαν συνελκτικά νευρωνικά δίκτυα και μέθοδοι ανίχνευσης αντικειμένων για να βελτιωθεί η ακρίβεια και η αποτελεσματικότητα της διαδικασίας αναγνώρισης και διαχείρισης των ασθενειών. Η μελέτη περιλαμβάνει τη συλλογή και προεπεξεργασία δεδομένων, την εκπαίδευση των νευρωνικών δικτύων χρησιμοποιώντας αλγορίθμους SSD και την αξιολόγηση της απόδοσης τους στην αναγνώριση ασθενειών των φυτών.

Στο θεωρητικό μέρος της έρευνας γίνεται ανάλυση των τεχνικών ανίχνευσης αντικειμένων και των νευρωνικών δικτύων, με εστίαση στην εφαρμογή τους στον τομέα της γεωργίας. Η μεθοδολογία περιγράφει αναλυτικά την προετοιμασία των δεδομένων, τη διαδικασία εκπαίδευσης των νευρωνικών δικτύων και την αξιολόγηση της αποτελεσματικότητας των αλγορίθμων SSD στην ανίχνευση ασθενειών των φυτών.



Κατάλογος Περιεχομένων

1. Εισαγωγή	6
1.1 Ανίχνευση ασθένειας φυτών	6
1.2 Στόχος εργασίας	6
1.3 Δομή εργασίας	6
2. Ανίχνευση Αντικειμένων με Υπολογιστική Όραση	8
2.1 Εισαγωγή	8
2.2 Συνελκτικά Νευρωνικά Δίκτυα (CNN)	8
2.3 Μονοσταδιακοί και Δισταδιακοί μέθοδοι Ανίχνευσης	10
2.4 Αλγόριθμοι Ανίχνευσης Αντικειμένων	12
2.5 Σχετική Έρευνα Αναγνώρισης Ασθένειας Φυτών	13
3. Εφαρμογή Ανίχνευσης Ασθένειας Φυτών	14
3.1 Εισαγωγή	14
3.2 Εργαλεία και περιβάλλον εκπαίδευσης	15
3.2.1 Google colab	15
3.2.2 Tensorflow	16
3.2.3 Tensorboard	17
3.3 Δημιουργία του Dataset	19
3.3.1 Εικόνες του Dataset	19
3.3.2 Labeling	20
3.3.3 Μετατροπή .xml σε .csv	22
3.3.4 Δημιουργία του labelmap	23
3.3.5 Δημιουργία των tfrecords	24
3.4 Δημιουργία μοντέλου	25
3.4.1 Επιλογή προ-εκπαιδευμένο μοντέλου	25
3.4.2 Διαμόρφωση του Μοντέλου	26



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.5 Εκπαίδευση με SSD.....	27
3.6 mean Average Precision (mAP)	32
4. Συμπεράσματα	33
5. Βιβλιογραφία	34



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

Λίστα Εικόνων

- [Εικόνα 1. Βασική δομή ενός Τεχνητού Νευρωνικού Δικτύου.](#)
- [Εικόνα 2. Μέθοδος ενός σταδίου.](#)
- [Εικόνα 3. Μέθοδος δύο σταδίων.](#)
- [Εικόνα 4. Μεθοδολογία εργασίας.](#)
- [Εικόνα 5. TensorBoard | TensorFlow .](#)
- [Εικόνα 6. <https://github.com/HumanSignal/labelImg.git>](#)
- [Εικόνα 7. \[0b494c44-8cd0-4491-bdfd-8a354209c3ae_RS_Erly.B 9561.jpg\]\(#\)](#)
- [Εικόνα 8. \[0b494c44-8cd0-4491-bdfd-8a354209c3ae_RS_Erly.B 9561.xml\]\(#\)](#)
- [Εικόνα 9. αρχείο csv για την εκπαίδευση](#)
- [Εικόνα 10. αρχείο labelmap](#)
- [Εικόνα 11.](#)
https://github.com/tensorflow/models/blob/master/research/object_detection/g3doc/tf2_detection_zoo.md
- [Εικόνα 12. Classification](#)
- [Εικόνα 13. Localization](#)
- [Εικόνα 14. Regularization loss](#)
- [Εικόνα 15. Total loss](#)
- [Εικόνα 16. Test Tomato_Late_blight 38%](#)
- [Εικόνα 17. Test Tomato_Early_blight](#)
- [Εικόνα 18. Test Tomato_mosaic_virus 70%](#)
- [Εικόνα 19. Tomato_Tomato_mosaic_virus](#)
- [Εικόνα 20. Test Tomato_healthy 95%](#)
- [Εικόνα 21. Tomato_healthy](#)



1. Εισαγωγή

1.1 Ανίχνευση ασθένειας φυτών

Στην Ελλάδα, πολλές καλλιέργειες αποτελούν αντικείμενο εμπορικής δραστηριότητας, με κάποιες από τις πιο δημοφιλείς να περιλαμβάνουν το σιτάρι, την ελιά, τα αμπέλια και τα φρούτα όπως η ντομάτα, το αχλάδι και το ροδάκινο. Ειδικά η καλλιέργεια της ελιάς και των αμπελιών αποτελεί σημαντικό κομμάτι της αγροτικής δραστηριότητας στην Ελλάδα, με τα προϊόντα τους να έχουν μεγάλη αξία τόσο στην εγχώρια όσο και στη διεθνή αγορά.

Οι γεωργικοί παράγοντες στην Ελλάδα αντιμετωπίζουν διάφορες προκλήσεις, όπως η εμφάνιση ασθενειών και ανεξέλεγκτων εντόμων που μπορούν να προκαλέσουν μείωση της παραγωγής και απώλειες στο εισόδημά τους. Η ανίχνευση και η αντιμετώπιση αυτών των ασθενειών και εντόμων αποτελεί σημαντική πρόκληση για τους αγρότες, καθώς οι παραδοσιακές μέθοδοι μπορεί να μην είναι αποτελεσματικές ή να απαιτούν υψηλό βαθμό εμπειρογνωμοσύνης.

1.2 Στόχος εργασίας

Στην παρούσα εργασία, επικεντρωνόμαστε στην ανίχνευση και την αντιμετώπιση ασθενειών των φυτών με τη χρήση σύγχρονων τεχνολογιών όπως οι αλγόριθμοι μηχανικής μάθησης. Αναπτύσσουμε ένα μοντέλο χρησιμοποιώντας αλγόριθμους μάθησης μηχανής, ώστε οι αγρότες να μπορούν εύκολα να ανιχνεύουν και να παρέχουν κατάλληλη θεραπεία για τις ασθένειες των φυτών. Η χρήση σύγχρονων τεχνολογιών όπως η μηχανική μάθηση μπορεί να βελτιώσει την αποτελεσματικότητα και την ακρίβεια της διαδικασίας ανίχνευσης και αντιμετώπισης των ασθενειών των φυτών, μειώνοντας έτσι τις απώλειες και ενισχύοντας την παραγωγικότητα στον γεωργικό τομέα της χώρας.

1.3 Δομή εργασίας

Το δεύτερο κεφάλαιο αναλύει το θεωρητικό υπόβαθρο της εργασίας, εστιάζοντας στην Ανίχνευση Αντικειμένων, τα Νευρωνικά Δίκτυα και τους σχετικούς αλγορίθμους που έχουν



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

αναπτυχθεί, παρέχοντας επίσης παραδείγματα από παρόμοιες έρευνες που εφαρμόζουν αλγορίθμους ανίχνευσης ασθενειών φυτών. Στο τρίτο κεφάλαιο παρουσιάζεται η μεθοδολογία που χρησιμοποιήθηκε στην εργασία, περιλαμβανομένων της προετοιμασίας των δεδομένων, της εκπαίδευσης των νευρωνικών δικτύων για τους αλγορίθμους SSD και της εφαρμογής τους στην ανίχνευση ασθενειών φυτών. Τέλος, στο τέταρτο κεφάλαιο αναλύονται τα συμπεράσματα της έρευνας, επισημαίνοντας τα κύρια ευρήματα και προτείνοντας πιθανές κατευθύνσεις για μελλοντικές έρευνες στον τομέα αυτόν.



2. Ανίχνευση Αντικειμένων με Υπολογιστική Όραση

2.1 Εισαγωγή

Η ανίχνευση αντικειμένων με υπολογιστική όραση αποτελεί μια σημαντική διαδικασία στον χώρο της τεχνητής νοημοσύνης και της υπολογιστικής όρασης. Αναπτύσσει τεχνικές για τον εντοπισμό και την κατηγοριοποίηση αντικειμένων μέσα σε εικόνες και βίντεο, με έμφαση στον αυτόματο εντοπισμό αντικειμένων χωρίς την ανθρώπινη παρέμβαση[1].

Η έμπνευση για την ανάπτυξη τέτοιων τεχνικών προέρχεται από την ανατροφοδότηση από τη λειτουργία του ανθρώπινου εγκεφάλου[2]. Οι πολυεπίπεδες δομές του εγκεφάλου αναλύουν την πληροφορία ανάλογα με τη σημασία της, ξεκινώντας από τα χαμηλού επιπέδου χαρακτηριστικά όπως τα άκρα και τις ακμές και συνεχίζοντας με υψηλότερου επιπέδου αφηρημένες αναπαραστάσεις όπως τα αντικείμενα. Αυτή η διαδικασία ενέπνευσε τη δημιουργία των συνελκτικών νευρωνικών δικτύων (CNNs), τα οποία αναπτύχθηκαν για να αναγνωρίζουν σημαντικά χαρακτηριστικά στις εικόνες με αυτόματο τρόπο, αντί να βασίζονται σε χειροκίνητα σχεδιασμένες αναπαραστάσεις[3].

Η ανίχνευση αντικειμένων έχει εφαρμογές σε πολλούς τομείς, από την αυτόνομη οδήγηση και την ασφάλεια των δημόσιων χώρων έως την ιατρική και την παρακολούθηση της άγριας φύσης. Με τη χρήση των CNNs και άλλων τεχνικών βαθιάς μάθησης, είναι δυνατόν να αναπτυχθούν συστήματα παρακολούθησης και προστασίας που μπορούν να ανιχνεύουν κίνηση, αντικείμενα ή συμπεριφορές που θεωρούνται ανομολόγητες.


2.2 Συνελκτικά Νευρωνικά Δίκτυα (CNN)

Τα Τεχνητά Νευρωνικά Δίκτυα (ANN) είναι υπολογιστικά συστήματα επεξεργασίας που αντλούν έμπνευση από τον τρόπο λειτουργίας των βιολογικών νευρικών συστημάτων, όπως είναι ο ανθρώπινος εγκέφαλος[2]. Τα τεχνητά Νευρωνικά Δίκτυα αποτελούνται κυρίως από πολλούς διασυνδεδεμένους υπολογιστικούς κόμβους, οι οποίοι ορίζονται ως νευρώνες και



λειτουργούν συνεργατικά για να μάθουν από την εισαγόμενη πληροφορία με στόχο τη βελτιστοποίηση της τελικής τους απόδοσης[3].

Η βασική δομή ενός Τεχνητού Νευρωνικού Δικτύου (ANN) μπορεί να περιγραφεί με τρεις βασικούς τύπους επιπέδων (όπως φαίνεται και στην Εικόνα 1.), το επίπεδο εισόδου, τα κρυφά επίπεδα και το επίπεδο εξόδου. Η είσοδος φορτώνεται σε μορφή πολυδιάστατου διανύσματος στο επίπεδο εισόδου, το οποίο διανέμει τα δεδομένα στα κρυφά επίπεδα. Τα κρυφά επίπεδα λαμβάνουν αποφάσεις από το προηγούμενο επίπεδο και εκτελούν αλγόριθμους μάθησης, όπως η προσαρμογή των βαρών τους με βάση την είσοδο. Η πολλαπλότητα των κρυφών επιπέδων που είναι στοιβαγμένα ο ένας πάνω στον άλλο συνήθως αναφέρεται ως βαθιά μάθηση[4].



Εικόνα 1. Βασική δομή ενός Τεχνητού Νευρωνικού Δικτύου.


Τα Συνελεκτικά νευρωνικά Δίκτυα (CNNs) είναι ένα είδος τεχνητών νευρωνικών δικτύων που χρησιμοποιούνται κυρίως στην επεξεργασία εικόνων. Κάθε CNN αποτελείται από τρία κύρια είδη επιπέδων: τα επίπεδα συνέλιξης χρησιμοποιούν φίλτρα για να εξάγουν χαρακτηριστικά από την είσοδο, τα επίπεδα συμπίεσης μειώνουν τις διαστάσεις των χαρακτηριστικών και τα πλήρως συνδεδεμένα επίπεδα εκτελούν την τελική κατηγοριοποίηση[5].



2.3 Μονοσταδιακοί και Δισταδιακοί μέθοδοι Ανίχνευσης

Οι μονοσταδιακοί (One-stage) και οι δισταδιακοί (Two-stage) μέθοδοι ανίχνευσης αντικειμένων είναι δύο διαφορετικές προσεγγίσεις που χρησιμοποιούνται στον τομέα της υπολογιστικής όρασης για τον εντοπισμό αντικειμένων σε εικόνες ή βίντεο. Κάθε μία από αυτές τις προσεγγίσεις έχει τα δικά της χαρακτηριστικά και πλεονεκτήματα, καθώς και τους αντίστοιχους περιορισμούς[6].

Οι μονοσταδιακοί μέθοδοι λειτουργούν με ένα μόνο στάδιο για τον εντοπισμό αντικειμένων, όπως φαίνεται στην Εικόνα 2. Αυτές οι μέθοδοι συνήθως χρησιμοποιούν πλήρως συνλεγμένα νευρωνικά δίκτυα με ενσωματωμένους μηχανισμούς εντοπισμού αντικειμένων. Κάθε pixel της εικόνας αξιολογείται απευθείας από το μοντέλο, χωρίς την ανάγκη για προεπεξεργασία ή επιλογή περιοχών ενδιαφέροντος. Αυτό καθιστά τις μονοσταδιακές μεθόδους ταχύτερες και πιο απλές στην υλοποίηση σε σχέση με τις δισταδιακές. Ωστόσο, σε περιπτώσεις μεγάλης ποικιλίας σε μέγεθος και θέσης των αντικειμένων δεν έχει μεγάλη ακρίβεια[7].



Εικόνα 2. Μέθοδος ενός σταδίου[6].

Αντίθετα, οι δισταδιακοί μέθοδοι χρησιμοποιούν δύο στάδια για τον εντοπισμό αντικειμένων, όπως φαίνεται στην Εικόνα 3. Αρχικά, ένα στάδιο παράγει προτάσεις περιοχών ενδιαφέροντος (region proposals) που πιθανόν να περιέχουν αντικείμενα και στη συνέχεια τα αντικείμενα ανιχνεύονται μέσω ενός δεύτερου σταδίου. Αυτή η προσέγγιση συνήθως παρέχει υψηλότερη ακρίβεια, καθώς έχει τη δυνατότητα να επεξεργάζεται λεπτομερέστερες πληροφορίες και να λαμβάνει υπόψη το περιβάλλον και το πλαίσιο των αντικειμένων. Ωστόσο, απαιτεί περισσότερους υπολογιστικούς πόρους και είναι πιο πολύπλοκη στην υλοποίηση σε σχέση με τις μονοσταδιακές μεθόδους[8].




321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>



Εικόνα 3. Μέθοδος δύο σταδίων[6].



2.4 Αλγόριθμοι Ανίχνευσης Αντικειμένων

Στην κατηγορία των δισταδιακών αλγορίθμων, ο Faster R-CNN ξεχωρίζει χρησιμοποιώντας ένα δίκτυο για τη δημιουργία προτάσεων περιοχών ενδιαφέροντος και ένα δεύτερο δίκτυο για τον εντοπισμό και την ταυτοποίηση αντικειμένων. Ο Mask R-CNN επεκτείνει αυτή τη δομή με ένα τρίτο στάδιο για την παραγωγή μάσκας πάνω στα αντικείμενα. Τέλος, ο Cascade R-CNN ενισχύει την ακρίβεια και την απόδοση εφαρμόζοντας σταδιακές προσεγγίσεις εντοπισμού[9].

Από την άλλη πλευρά, οι μονοσταδιακοί αλγόριθμοι προσφέρουν εξίσουν ενδιαφέρουσες λύσεις. Ο αλγόριθμος YOLO (You Only Look Once) επιτρέπει τον εντοπισμό αντικειμένων εφαρμόζοντας ένα μόνο νευρωνικό δίκτυο σε ολόκληρη την εικόνα. Ο SDD (Single Shot MultiBox Detector) επικεντρώνεται στην ταχύτητα χρησιμοποιώντας ένα μόνο δίκτυο για τον εντοπισμό αντικειμένων. Τέλος, ο RetinaNet βελτιώνει την ακρίβεια εστιάζοντας την ανίχνευση αντικειμένων σε διαφορετικές κλίμακες[10].

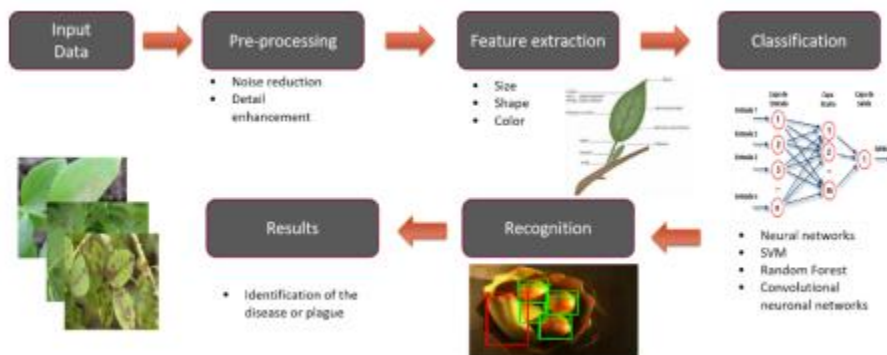


2.5 Σχετική Έρευνα Αναγνώρισης Ασθένειας Φυτών

1. Diseases Detection in Blueberry Leaves using Computer Vision and Machine Learning Techniques.

Το 2019, μία ομάδα ερευνητών πραγματοποίησε μία μελέτη με σκοπό την ανίχνευση ασθενειών στα φύλλα των μυρτιλλιών χρησιμοποιώντας τεχνικές Υπολογιστικής Όρασης και Μηχανικής Μάθησης[11]. Στόχος της έρευνας ήταν να αναπτυχθεί ένα σύστημα που θα μπορούσε να αναγνωρίσει αν ένα φυτό μυρτιλλιάς επηρεάζεται από ασθένεια ή επιβλαβές οργανισμό, ή αν είναι υγιές.

Η μεθοδολογία της έρευνας όπως φαίνεται στην Εικόνα 4. περιλάμβανε τη συλλογή φωτογραφιών διαφόρων ποικιλιών μυρτιλλιών από φάρμες στην Καλιφόρνια και το Περού. Οι εικόνες στη συνέχεια επεξεργάστηκαν για να εξαχθούν χαρακτηριστικά, μεταξύ άλλων μέσω της μεθόδου HoG (Histograms of Oriented Gradient) και της μεθόδου LBP (Local Binary Patter) για την εξαγωγή χαρακτηριστικών από τις εικόνες.



Εικόνα 4. Μεθοδολογία εργασίας[11].

Τα δεδομένα εκπαιδεύτηκαν με τέσσερις διαφορετικούς αλγορίθμους μάθησης: Μηχανές Διανυσμάτων Υποστήριξης (SVM), Τυχαίο Δάσος (Random Forest), Νευρωνικά Δίκτυα (Neural Networks) και Συνελκτικά Νευρωνικά Δίκτυα (Convolution Neural Networks). Τα αποτελέσματα έδειξαν ότι η χρήση του αλγορίθμου CNN με την μέθοδο Deep Learning και την εξαγωγή χαρακτηριστικών μέσω της μεθόδου LBP είχε την υψηλότερη ακρίβεια, με ποσοστό 84% στην ανίχνευση της κατάστασης των φύλλων μυρτιλλιάς.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3. Εφαρμογή Ανίχνευσης Ασθένειας Φυτών

3.1 Εισαγωγή

Στην συγκεκριμένη εργασία, η απόφαση να χρησιμοποιηθεί ο αλγόριθμος SSD για τη δημιουργία ενός μοντέλου ανίχνευσης ασθενειών σε φύλλα ντομάτας βασίστηκε στην αξιοπιστία και την απόδοσή του. Ο SSD θεωρείται ως ο πιο γρήγορος two-stage αλγόριθμος, προσφέροντας ταυτόχρονα υψηλή ακρίβεια στην ανίχνευση αντικειμένων.

Ένα από τα πρώτα βήματα που ακολουθήθηκαν ήταν η προετοιμασία του dataset. Το dataset προήλθε από την πλατφόρμα Kaggle και περιελάμβανε εικόνες από φύλλα ντομάτας. Έγινε προσεκτικά ο διαχωρισμός του συνόλου δεδομένων σε σύνολα εκπαίδευσης και αξιολόγησης.

Κατά τη διάρκεια της εκπαίδευσης του μοντέλου, χρησιμοποιήθηκαν κάποιες από τις εικόνες του dataset για τον έλεγχο της προόδου και την εκτίμηση της απόδοσης του αλγορίθμου. Αυτή η διαδικασία επέτρεψε την παρακολούθηση της εξέλιξης του μοντέλου και την ενδελεχή ανάλυση των αποτελεσμάτων της εκπαίδευσης.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.2 Εργαλεία και περιβάλλον εκπαίδευσης

3.2.1 Google colab

Χρησιμοποιήθηκε το Google Colab, ένα προηγμένο εργαλείο ανάπτυξης και εκτέλεσης κώδικα Python στο cloud, το οποίο προσφέρει ευελιξία και δωρεάν πρόσβαση σε ισχυρούς υπολογιστικούς πόρους. Χρησιμοποιείται ευρέως για τη δημιουργία και εκτέλεση notebooks Python από οποιονδήποτε υπολογιστή με πρόσβαση στο internet, χωρίς την ανάγκη να εγκατασταθεί περιβάλλον ανάπτυξης στον τοπικό υπολογιστή. Με τη δυνατότητα πρόσβασης σε GPU και TPU, προσφέρει επιτάχυνση στην εκπαίδευση μοντέλων μηχανικής μάθησης, ενώ η εύκολη εγκατάσταση βιβλιοθηκών Python, συμπεριλαμβανομένου του TensorFlow, το καθιστά ιδιαίτερα κατάλληλο για πειραματική ανάπτυξη και αξιολόγηση αλγορίθμων.

Επιπλέον, το Google Colab διευκολύνει τη συνεργασία και την κοινή χρήση notebooks μεταξύ πολλών χρηστών, επιτρέποντας τους να εργάζονται ταυτόχρονα σε ένα project. Με την ενσωμάτωση ισχυρών εργαλείων οπτικοποίησης όπως το TensorBoard, παρέχει αναλυτική αξιολόγηση και βελτιστοποίηση μοντέλων μηχανικής μάθησης μέσω οπτικών γραφημάτων και μετρήσεων.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.2.2 Tensorflow

Χρησιμοποιήθηκε το TensorFlow για την ανάπτυξη και εκπαίδευση αλγορίθμων μηχανικής μάθησης και βαθιάς μάθησης. Το TensorFlow αναπτύχθηκε αρχικά από την Google και έχει αποκτήσει ευρεία αποδοχή στην κοινότητα των ερευνητών και προγραμματιστών λόγω της ευελιξίας και της ικανότητάς του να υποστηρίζει πληθώρα εφαρμογών.

Ένα από τα σημαντικότερα χαρακτηριστικά του TensorFlow είναι η ικανότητα να χειρίζεται μεγάλα σύνολα δεδομένων και να επιτρέπει την αποδοτική εκπαίδευση σύνθετων μοντέλων, όπως είναι το SSD (Single Shot MultiBox Detector). Οι βιβλιοθήκες και τα εργαλεία που προσφέρει καθιστούν δυνατή την εύκολη υλοποίηση αλγορίθμων βαθιάς μάθησης και την ενσωμάτωσή τους σε ποικίλες εφαρμογές, από ανίχνευση αντικειμένων έως αναγνώριση φωνής και ανάλυση εικόνας.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.2.3 Tensorboard

Κατά τη διάρκεια της εκπαίδευσης, το TensorBoard κατέγραψε τα δεδομένα της εκπαίδευσης σε περιοδικά αρχεία και μετά την ολοκλήρωσή της, χρησιμοποιήθηκε για την αξιολόγηση του εκπαιδευμένου δικτύου. Αυτή η διαδικασία εμπλουτίστηκε με τον οπτικό έλεγχο των δεδομένων και των μετρήσεων χάρη στην ευκολία που προσφέρει το TensorBoard στην οπτικοποίηση των αποτελεσμάτων.

Το TensorBoard προσφέρει ένα ευρύ φάσμα εργαλείων οπτικοποίησης, από γραφήματα ακρίβειας και απώλειας κατά τη διάρκεια της εκπαίδευσης μέχρι τις μετρήσεις απόδοσης κατά την αξιολόγηση του μοντέλου. Μέσω της οπτικοποίησης, οι χρήστες μπορούν να παρακολουθούν την πρόοδο της εκπαίδευσης, να εντοπίζουν πιθανά προβλήματα και να λαμβάνουν στρατηγικές αποφάσεις για βελτίωση της απόδοσης του μοντέλου, όπως φαίνεται στην Εικόνα 5.



Εικόνα 5. [TensorBoard](#) | [TensorFlow](#)

Τα αρχεία τύπου .tfevents, τα οποία δημιουργούνται κατά την εκπαίδευση, παρέχουν αναλυτική εικόνα της εκπαίδευσης, ενώ οι αρχεία που προκύπτουν από την αξιολόγηση παρέχουν μετρήσεις απόδοσης όπως ο μέσος όρος της ακρίβειας και της ανάκλησης. Επίσης, η οπτικοποίηση των αρχείων εκπαίδευσης και αξιολόγησης μπορεί να παρέχει εικόνες με τα δείγματα που χρησιμοποιήθηκαν στην αξιολόγηση, επιτρέποντας την εκτίμηση της απόδοσης του μοντέλου σε πραγματικά δεδομένα.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>



3.3 Δημιουργία του Dataset

3.3.1 Εικόνες του Dataset

Το Dataset που χρησιμοποιήθηκε για την εκπαίδευση του μοντέλου ανίχνευσης ασθενειών σε φύλλα ντομάτας προήλθε από την πλατφόρμα Kaggle. Το σύνολο εικόνων διαχωρίστηκε αρχικά σε τρία διαφορετικά σύνολα για τις ανάγκες εκπαίδευσης του μοντέλου: το σύνολο εκπαίδευσης (train 80%), το σύνολο αξιολόγησης (validation, 10%) και το σύνολο ελέγχου (test, 10%).

Το Dataset περιλαμβάνει εικόνες που αντιπροσωπεύουν διάφορες κατηγορίες ασθενειών σε φύλλα ντομάτας, συνολικά εννέα κατηγορίες. Αυτές οι κατηγορίες περιλαμβάνουν:

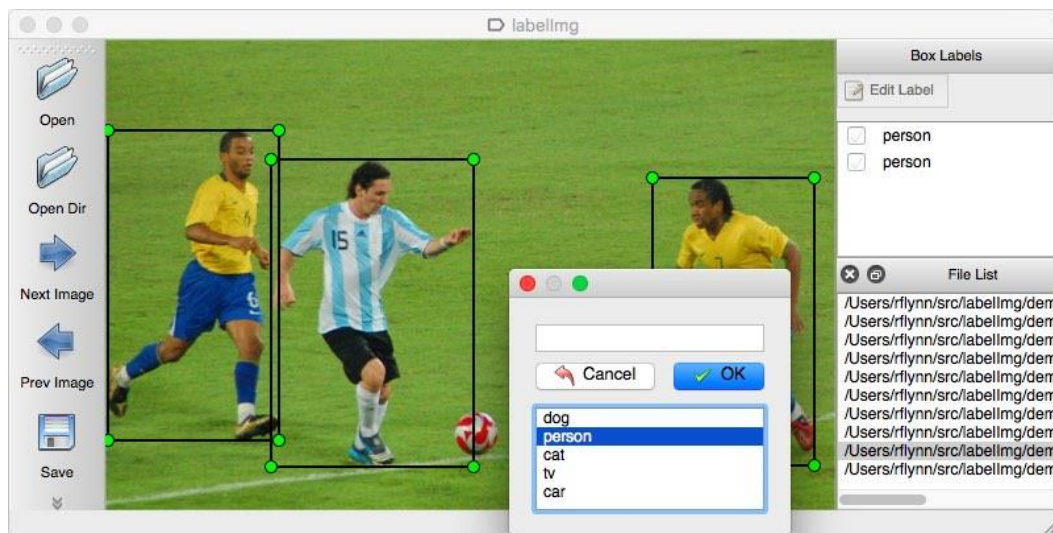
1. Tomato__Tomato_mosaic_virus
2. Tomato__Tomato_YellowLeaf__Curl_Virus
3. Tomato_Bacterial_spot
4. Tomato_Early_blight
5. Tomato_healthy
6. Tomato_Late_blight
7. Tomato_Leaf_Mold
8. Tomato_Septoria_leaf_spot
9. Tomato_Spider_mites_Two-spotted_spider_mite



3.3.2 Labeling

Το Labeling είναι η διαδικασία κατηγοριοποίησης και επισημείωσης εικόνων για τη δημιουργία ενός Dataset που θα χρησιμοποιηθεί στην εκπαίδευση Νευρωνικών Δικτύων Υπολογιστικής Όρασης. Αυτή η διαδικασία είναι ουσιώδης για την επιτυχή εκπαίδευση του μοντέλου να αναγνωρίζει και να ταξινομεί αυτόματα αντικείμενα ή παρασκευάσματα εικόνων σε μια δοσμένη εικόνα.

Το λογισμικό LabelImg, όπως παρουσιάζεται στην Εικόνα 6, επιτρέπει στους χρήστες να επισημειώσουν χειροκίνητα τις εικόνες με Bounding Boxes γύρω από αντικείμενα ή περιοχές ενδιαφέροντος, όπως ελαττώματα σε ντομάτες στην προκειμένη περίπτωση. Αυτές οι περιοχές επισημείωσης αποθηκεύονται σε μορφή XML για κάθε εικόνα, παρέχοντας σημαντικές πληροφορίες όπως το όνομα της εικόνας, η διαδρομή της εικόνας, το μέγεθος της, οι συντεταγμένες του bounding box κάθε αντικειμένου καθώς και άλλες λεπτομέρειες όπως η κατηγορία του αντικειμένου, η θέση (pose), και άλλες επιπρόσθετες παραμέτρους.



Εικόνα 6. <https://github.com/HumanSignal/labelImg.git>

Για παράδειγμα, η εικόνα 0b494c44-8cd0-4491-bdfd-8a354209c3ae__RS_Erly.B 9561.jpg απεικονίζει την πρώτη λοίμωξη στα φύλλα των ντομάτας.




321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>



Εικόνα 7. 0b494c44-8cd0-4491-bdfd-8a354209c3ae___RS_Erly.B 9561.jpg

Χρησιμοποιώντας το LabelImg, δημιουργήτε το αντίστοιχο XML Εικόνα 7. Αυτό το αρχείο περιέχει όλες τις απαραίτητες πληροφορίες που απαιτούνται για να εκπαιδευτεί ένα Νευρωνικό Δίκτυο να αναγνωρίζει την πρώιμη λοίμωξη στις ντομάτες στη συγκεκριμένη εικόνα..

```
<annotation>
  <folder>Tomato_Early_blight</folder>
  <filename>0b494c44-8cd0-4491-bdfd-8a354209c3ae___RS_Erly.B 9561.JPG</filename>
  <path>C:\Users\athan\Desktop\images\Tomato_Early_blight\0b494c44-8cd0-4491-bdfd-8a354209c3ae___RS_Erly.B 9561.JPG</path>
  <source>
    <database>Unknown</database>
  </source>
  <size>
    <width>256</width>
    <height>256</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>Tomato_Early_blight</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <difficult>0</difficult>
    <bndbox>
      <xmin>17</xmin>
      <ymin>8</ymin>
      <xmax>228</xmax>
      <ymax>251</ymax>
    </bndbox>
  </object>
</annotation>
```

Εικόνα 8. 0b494c44-8cd0-4491-bdfd-8a354209c3ae___RS_Erly.B 9561.xml



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.3.3 Μετατροπή .xml σε .csv

Η μετατροπή των .xml αρχείων σε .csv είναι ένα σημαντικό βήμα για τη βελτιστοποίηση της διαχείρισης των δεδομένων κατά την εκπαίδευση Νευρωνικών Δικτύων. Η διαδικασία αυτή προσφέρει πολλαπλά πλεονεκτήματα, κάνοντας τα δεδομένα πιο εύκολα προσβάσιμα και επεξεργάσιμα. Η διαδικασία μετατροπής περιλαμβάνει την ανάγνωση των δεδομένων από τα .xml αρχεία, την εξαγωγή των αναγκαίων πληροφοριών και την καταγραφή τους σε ένα .csv αρχείο.

Η Εικόνα 9 παρουσιάζει ένα τμήμα του .csv αρχείου που χρησιμοποιήθηκε για την εκπαίδευση των Νευρωνικών Δικτύων. Σε αυτό το αρχείο, Κάθε γραμμή του .csv αρχείου αντιπροσωπεύει ένα αντικείμενο που εντοπίζεται μέσα σε μια εικόνα. Οι στήλες παρέχουν όλες τις απαραίτητες πληροφορίες για την αναγνώριση και την τοποθέτηση του αντικειμένου μέσα στην εικόνα.

	A	B	C	D	E	F	G	H
1	filename	width	height	class	xmin	ymin	xmax	ymax
2	000b685-b305-408b-91f4-37030f8e62db_GH_HL_Leaf_308.1.JPG	256	256	Tomato_healthy	49	11	213	244
3	000ec6ea-9063-4c33-8abe-d58ca8a88878_PSU_CG_2169.JPG	256	256	Tomato_Tomato_mosaic_virus	46	41	198	246
4	00a538f3-8421-43ab-9e6f-758d36180dd3_YLCV_NREC_2667.JPG	256	256	Tomato_Tomato_YellowLeaf_Curl_Virus	41	24	216	241
5	00a7c269-3476-4d25-b744-44d6353cd921_GCRC_Bact.Sp_5807.JPG	256	256	Tomato_Bacterial_spot	32	7	215	254
6	00b41556-fe22-41fb-93aa-76b0c45d923a_UF_GRC_YLCV_Lab_02644.JPG	256	256	Tomato_Tomato_YellowLeaf_Curl_Virus	39	25	226	238
7	00b7e89a-e129-4576-b51f-48923888bf99_GCRC_Bact.Sp_6202.JPG	256	256	Tomato_Bacterial_spot	51	17	208	244
8	00b814ee-cfa9-489a-bed3-c1f927bef05a_YLCV_NREC_0220.JPG	256	256	Tomato_Tomato_YellowLeaf_Curl_Virus	45	35	212	239
9	00bc7858-1dca-4bfb-a828-225f03bd72a5_Com.G_SpM_FL_9455.JPG	256	256	Tomato_Spider_mites_Two_spotted_spider_mite	66	84	192	236
10	00bce074-967b-4d50-967a-31fdaa35e688_RS_HL_0223.JPG	256	256	Tomato_healthy	30	13	234	238
11	00c07a77-15e6-4815-92d4-8d1e1afb7f3c_PSU_CG_2052.JPG	256	256	Tomato_Tomato_mosaic_virus	59	19	207	236
12	00c16232-5beb-41a1-9a05-b18a02f10ca1_YLCV_NREC_2536.JPG	256	256	Tomato_Tomato_YellowLeaf_Curl_Virus	27	7	238	233
13	00c5c908-fc25-4710-a109-db143da23112_RS_Erly.B_7778.JPG	256	256	Tomato_Early_blight	31	21	220	238
14	00c8e9a0-1fb8-434b-8981-25511358ddc9_Com.G_SpM_FL_8717.JPG	256	256	Tomato_Spider_mites_Two_spotted_spider_mite	78	53	209	231

Εικόνα 9. αρχείο csv για την εκπαίδευση



3.3.4 Δημιουργία του labelmap

Για την εκπαίδευση, δημιουργήθηκε ένα αρχείο labelmap σύμφωνα με τις απαιτήσεις του Tensorflow. Αυτό το αρχείο έχει μορφή .pbtxt και περιγράφει τις κλάσεις για τις οποίες πρόκειται να γίνει εκπαίδευση του μοντέλου. Κάθε κλάση αναπαρίσταται ως ένα αντικείμενο τύπου "item" με δύο παραμέτρους: το "id" και το "name".

Στη συγκεκριμένη εργασία, όπου υπάρχουν 9 κλάσεις αντικειμένων για εκπαίδευση, το αρχείο labelmap περιλαμβάνει αντικείμενα τύπου "item" με id από 1 μέχρι 9 και το όνομα της κάθε κλάσης αντιστοιχεί στην κατηγορία των φυτών κασάβας που πρόκειται να ανιχνευθούν, επομένως το labelmap αρχείο που δημιουργήθηκε είχε την μορφή της Εικόνας 10.

```
item {
  id: 1
  name: 'Tomato__Tomato_mosaic_virus'
}
item {
  id: 2
  name: 'Tomato__Tomato_YellowLeaf__Curl_Virus'
}
item {
  id: 3
  name: 'Tomato_Bacterial_spot'
}
item {
  id: 4
  name: 'Tomato_Early_blight'
}
item {
  id: 5
  name: 'Tomato_healthy'
}
item {
  id: 6
  name: 'Tomato_Late_blight'
}
item {
  id: 7
  name: 'Tomato_Leaf_Mold'
}
item {
  id: 8
  name: 'Tomato_Septoria_leaf_spot'
}
item {
  id: 9
  name: 'Tomato_Spider_mites_Two_spotted_spider_mite'
}
```

Εικόνα 10. αρχείο labelmap



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.3.5 Δημιουργία των tfrecords

Τα TFRecord αρχεία αποτελούν ένα ειδικό δυαδικό μορφότυπο που χρησιμοποιείται από το Tensorflow για την αποθήκευση και αποτελεσματική επεξεργασία μεγάλων συνόλων δεδομένων. Το κάθε TFRecord αρχείο περιέχει δεδομένα σε μορφή που είναι ειδικά διαμορφωμένη για τη χρήση με το Tensorflow, επιτρέποντας την αποδοτική φόρτωση και επεξεργασία αυτών των δεδομένων κατά τη διάρκεια της εκπαίδευσης των μοντέλων μηχανικής μάθησης.

Η δημιουργία των TFRecord αρχείων γίνεται μέσω ενός Python script, το οποίο αναλαμβάνει τη μετατροπή των αρχικών δεδομένων σε μορφή TFRecord. Το script διαβάζει τα δεδομένα από αρχεία .csv και τα διαμορφώνει σε μορφή που είναι συμβατή με τη δομή των TFRecord. Με αυτήν τη διαδικασία, τα δεδομένα προετοιμάζονται για τη χρήση από τα μοντέλα μηχανικής μάθησης του Tensorflow, εξασφαλίζοντας τη βελτιστοποίηση της απόδοσης και την αποτελεσματική χρήση των δεδομένων κατά τη διάρκεια της εκπαίδευσης των μοντέλων.



3.4 Δημιουργία μοντέλου

3.4.1 Επιλογή προ-εκπαιδευμένο μοντέλου

Η επιλογή προ-εκπαιδευμένων μοντέλων είναι κρίσιμη για τη διαδικασία εκπαίδευσης μοντέλων μηχανικής μάθησης. Η επιλογή αλγορίθμου επηρεάζει την ταχύτητα και την ακρίβεια του αποτελέσματος. Εάν η ακρίβεια είναι κρίσιμη, επιλέγεται αλγόριθμος με υψηλό mAP. Σε περιπτώσεις όπου η ταχύτητα είναι πιο σημαντική, προτιμούνται οι γρηγορότεροι αλγόριθμοι.

Model name	Speed (ms)	COCO mAP	Outputs
SSD MobileNet v2 320x320	19	20.2	Boxes
SSD MobileNet V1 FPN 640x640	48	29.1	Boxes
SSD MobileNet V2 FPNLite 320x320	22	22.2	Boxes
SSD MobileNet V2 FPNLite 640x640	39	28.2	Boxes
SSD ResNet50 V1 FPN 640x640 (RetinaNet50)	46	34.3	Boxes
SSD ResNet50 V1 FPN 1024x1024 (RetinaNet50)	87	38.3	Boxes
SSD ResNet101 V1 FPN 640x640 (RetinaNet101)	57	35.6	Boxes
SSD ResNet101 V1 FPN 1024x1024 (RetinaNet101)	104	39.5	Boxes
SSD ResNet152 V1 FPN 640x640 (RetinaNet152)	80	35.4	Boxes
SSD ResNet152 V1 FPN 1024x1024 (RetinaNet152)	111	39.6	Boxes

Εικόνα 11.

https://github.com/tensorflow/models/blob/master/research/object_detection/g3doc/tf2_detection_zoo.md

Στη συγκεκριμένη εργασία, επιλέχθηκε το μοντέλο SSD MobileNet V2 FPNLite 320x320 το οποίο σύμφωνα με τη λίστα των μοντέλων έχει ακρίβεια 22.2 mAP στο COCO Dataset, από το TensorFlow 2 Detection Model Zoo.



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

3.4.2 Διαμόρφωση του Μοντέλου

Η διαμόρφωση του μοντέλου αποτελεί ένα κρίσιμο στάδιο στη διαδικασία εκπαίδευσης μοντέλων ανίχνευσης αντικειμένων. Κάθε μοντέλο χρησιμοποιεί ένα αρχείο ρυθμίσεων για την αρχικοποίηση των παραμέτρων της εκπαίδευσης και την αξιολόγησή του. Αυτό το αρχείο, το οποίο συνήθως έχει μορφή `.config` ή `.cfg`, περιέχει πληροφορίες που καθορίζουν τη συμπεριφορά και τη δομή του μοντέλου κατά τη διάρκεια της εκπαίδευσης.

Ανάμεσα στις βασικές παραμέτρους που καθορίζονται σε αυτό το αρχείο είναι οι διαστάσεις των εικόνων που θα χρησιμοποιηθούν κατά την εκπαίδευση, ο αριθμός των επαναλήψεων εκπαίδευσης, το μέγεθος των ομάδων εισόδου (batch size), ο ρυθμός μάθησης (learning rate) και οι διαδρομές προς τα αρχεία του Dataset, όπως οι διαδρομές για τις εικόνες εκπαίδευσης και αξιολόγησης καθώς και οι διαδρομές για το labelmap και το προ-εκπαιδευμένο μοντέλο.




3.5 Εκπαίδευση με SSD

Στο πλαίσιο της εκπαίδευσης ενός μοντέλου SSD (Single Shot MultiBox Detector) στο περιβάλλον Google Colab, η διαμόρφωση του μοντέλου περιλάμβανε λεπτομερείς ρυθμίσεις για την επίτευξη βέλτιστων αποτελεσμάτων. Χρησιμοποιήθηκε το SSD με χαρακτηριστικό εξαγωγέα το MobileNet v2 και το FPN-lite για την ανάκτηση πολυεπίπεδων χαρακτηριστικών, ενώ η εκπαίδευση πραγματοποιήθηκε με εφαρμογή συγκεκριμένων μεθόδων βελτιστοποίησης και μέτρων αύξησης δεδομένων για βελτίωση της γενίκευσης.

Η εντολή εκπαίδευσης περιλάμβανε τον καθορισμό των απαιτούμενων παραμέτρων, όπως τον βηματικό ρυθμό μάθησης με βάση τη μέθοδο cosine decay για ομαλή μείωση, το μέγιστο αριθμό βημάτων σε 20000, και το batch size στη μέγιστη δυνατή τιμή για τη διαθέσιμη μνήμη. Επιπλέον, χρησιμοποιήθηκε προεκπαιδευμένο checkpoint από το COCO dataset για βελτιστοποίηση της απόδοσης του μοντέλου SSD στον ανιχνευτή αντικειμένων.

Το διάγραμμα Classification Loss (Απώλεια Κατηγοριοποίησης) παρουσιάζει την εξέλιξη της απώλειας κατηγοριοποίησης κατά τη διάρκεια της εκπαίδευσης. Η απώλεια κατηγοριοποίησης μετρά το πόσο καλά το μοντέλο αναγνωρίζει τις κατηγορίες των αντικειμένων. Η μείωση της απώλειας κατηγοριοποίησης κατά την πρόοδο της εκπαίδευσης σημαίνει ότι το μοντέλο βελτιώνεται στην αναγνώριση των κατηγοριών των αντικειμένων.

Classification loss



Εικόνα 12. Classification

Το διάγραμμα Localization Loss (Απώλεια Εντοπισμού) απεικονίζει την απώλεια εντοπισμού κατά την εκπαίδευση. Η απώλεια εντοπισμού μετρά την ακρίβεια με την οποία το μοντέλο



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

μπορεί να εντοπίζει τις ακριβείς θέσεις των αντικειμένων στις εικόνες. Η μείωση αυτής της απώλειας δείχνει τη βελτίωση της ακρίβειας του μοντέλου στον εντοπισμό των αντικειμένων.


Localization



Εικόνα 13. Localization

Το διάγραμμα Regularization Loss (Απώλεια Ρύθμισης) αναπαριστά την απώλεια ρύθμισης κατά την εκπαίδευση. Η απώλεια ρύθμισης συμβάλλει στην αποφυγή υπερπροσαρμογής (overfitting) και στη βελτίωση της γενίκευσης του μοντέλου. Μια σταθερή ή μειωμένη απώλεια ρύθμισης είναι επιθυμητή κατά την εκπαίδευση.

Regularization loss



Εικόνα 14. Regularization loss



321-6600– Προηγμένη Ρομποτική


Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>


Το διάγραμμα Total Loss (Συνολική Απώλεια) παρουσιάζει τη συνολική απώλεια του μοντέλου κατά την εκπαίδευση, η οποία αποτελεί το άθροισμα της απώλειας κατηγοριοποίησης, της απώλειας εντοπισμού και της απώλειας ρύθμισης. Η εξέταση της συνολικής απώλειας μας δίνει μια ολιστική εικόνα της απόδοσης του μοντέλου κατά την εκπαίδευση και μπορεί να χρησιμοποιηθεί για την προσαρμογή των παραμέτρων της εκπαίδευσης.

Total loss



Εικόνα 15. Total loss


Οι εικόνες 16 έως 21 παρουσιάζουν τα αποτελέσματα του μοντέλου SSD (Single Shot MultiBox Detector).



Εικόνα 16. Test Tomato_Late_blight 38% Εικόνα 17. Test Tomato_Early_blight



Η εικόνα 17 είχε χαρακτηριστεί ως Test Tomato_Early_blight, αλλά το μοντέλο την αναγνώρισε ως Tomato_Late_blight με ακρίβεια 38%. Αυτό δείχνει ότι το μοντέλο αντιμετωπίζει δυσκολίες στη διάκριση μεταξύ αυτών των δύο ασθενειών, πιθανώς λόγω παρόμοιων οπτικών χαρακτηριστικών.




Εικόνα 18. Test Tomato_mosaic_virus 70%

Tomato__Tomato_mosaic_virus



Εικόνα 19.

Η εικόνα 19 είχε χαρακτηριστεί ως Test Tomato_mosaic_virus και το μοντέλο την αναγνώρισε ως Tomato_mosaic_virus με ακρίβεια 70%. Το υψηλότερο ποσοστό ακρίβειας υποδεικνύει ότι το μοντέλο είναι αρκετά ικανό να εντοπίζει σωστά αυτή την ασθένεια, πιθανώς λόγω καλύτερων ή περισσότερων δεδομένων εκπαίδευσης.



Εικόνα 20. Test Tomato_healthy 95%



Εικόνα 21. Tomato_healthy

Η εικόνα 21 είχε χαρακτηριστεί ως Test Tomato_healthy και το μοντέλο την αναγνώρισε σωστά ως Tomato_healthy με ακρίβεια 95%. Το πολύ υψηλό ποσοστό ακρίβειας δείχνει ότι το



321-6600– Προηγμένη Ρομποτική

Τίτλος Μελέτης: Αναγνώριση ασθένειας φυτών με υπολογιστική όραση

321/2020048 Γρηγορίδου Αθανασία

<https://github.com/agrigoridou/Tomato-Leaf-Diseases-TensorFlow-Object-Detection.git>

μοντέλο μπορεί να διακρίνει πολύ καλά τα υγιή φυτά από τα άρρωστα, κάτι που είναι κρίσιμο για την αποτελεσματική εφαρμογή σε πραγματικά δεδομένα.



3.6 mean Average Precision (mAP)

Το Mean Average Precision (mAP) είναι ένα σημαντικό μέτρο αξιολόγησης για μοντέλα ανίχνευσης αντικειμένων σε εικόνες, το οποίο αξιολογεί την ικανότητά τους να αναγνωρίζουν και να τοποθετούν σωστά αντικείμενα σε διάφορες κατηγορίες. Το mAP υπολογίζεται βασισμένο στο Precision και το Recall για κάθε κατηγορία αντικειμένου, σε διάφορα επίπεδα IoU (Intersection over Union), τα οποία καλύπτουν την επικάλυψη μεταξύ των προβλεπόμενων και πραγματικών περιοχών των αντικειμένων. Η μέση τιμή του mAP υποδεικνύει την συνολική απόδοση του μοντέλου σε όλες τις κατηγορίες, καθιστώντας το κρίσιμο για την εκτίμηση και βελτίωση της ακρίβειας της αναγνώρισης αντικειμένων σε πραγματικές συνθήκες.

Οι τύποι Precision και Recall αποτελούν κρίσιμες μετρικές για την αξιολόγηση της απόδοσης του μοντέλου. Η Precision μετρά την ακρίβεια των αναγνωρισμένων αντικειμένων σε σχέση με τις συνολικές προβλεπόμενες περιοχές. Παράδειγμα, μια υψηλή Precision υποδεικνύει ότι η πλειονότητα των προβλεπόμενων αντικειμένων πραγματικά ανήκουν στην κατηγορία τους. Η Recall αξιολογεί την ικανότητα του μοντέλου να εντοπίζει όλα τα πραγματικά αντικείμενα μιας κατηγορίας. Συνήθως, υψηλότερες τιμές της Recall σημαίνουν ότι το μοντέλο μπορεί να εντοπίζει τα περισσότερα πραγματικά αντικείμενα, αλλά μπορεί να υπάρχουν και περισσότερα λανθασμένα θετικά.

Από τα αποτελέσματα που παρουσιάζονται, προκύπτει ότι η συνολική απόδοση του μοντέλου στις δοκιμαστικές εικόνες είναι περίπου 26.30% mAP. Οι κατηγορίες με την υψηλότερη ακρίβεια και Recall είναι η "Tomato_Late_blight", η "Tomato_Septoria_leaf_spot", και η "Tomato_Tomato_YellowLeaf_Curl_Virus", δείχνοντας ότι το μοντέλο είναι αποτελεσματικό στην αναγνώριση αυτών των κατηγοριών. Αντιθέτως, οι κατηγορίες όπως η "Tomato_Bacterial_spot" και η "Tomato_Early_blight" εμφανίζουν πολύ χαμηλή Precision, υποδεικνύοντας ότι το μοντέλο πρέπει να βελτιωθεί στην αναγνώριση αυτών των συγκεκριμένων κατηγοριών για μια πιο ολοκληρωμένη απόδοση. Αυτή η ανάλυση είναι κρίσιμη για την προσαρμογή και βελτίωση του μοντέλου, προκειμένου να επιτύχει καλύτερη ακρίβεια και αξιοπιστία στην αναγνώριση αντικειμένων σε πραγματικές συνθήκες χρήσης.



4. Συμπεράσματα

Η παρούσα έρευνα επικεντρώθηκε στην ανίχνευση και αντιμετώπιση ασθενειών των φυτών με τη χρήση σύγχρονων τεχνολογιών, όπως οι αλγόριθμοι μηχανικής μάθησης. Αρχικά, αναδείξαμε τη σημασία των καλλιεργειών στην ελληνική γεωργία, εστιάζοντας σε καλλιέργειες όπως το σιτάρι, η ελιά, τα αμπέλια και τα φρούτα, και τις προκλήσεις που αντιμετωπίζουν οι αγρότες λόγω ασθενειών και εντόμων. Εφαρμόσαμε μεθοδολογία που περιλάμβανε την προετοιμασία δεδομένων, την εκπαίδευση συνεκλεκτικών νευρωνικών δικτύων (CNNs) με αλγόριθμους SSD, και την ανάπτυξη μοντέλου για την ακριβή ανίχνευση ασθενειών φυτών. Τα αποτελέσματα κατέδειξαν την αποτελεσματικότητα του προτεινόμενου μοντέλου στη μείωση απωλειών καλλιεργειών, ενώ η χρήση της μηχανικής μάθησης βελτίωσε την αποδοτικότητα της ανίχνευσης και αντιμετώπισης ασθενειών φυτών.

Ωστόσο, αντιμετωπίσαμε κάποια προβλήματα κατά την εκπαίδευση του μοντέλου. Συγκεκριμένα, λόγω των περιορισμένων πόρων στο Google Colab, η διαδικασία διακόπτονταν αυτόματα λόγω ανίατων διακοπών σύνδεσης, παρά τις προσπάθειές μας να θέσουμε τον αριθμό των βημάτων εκπαίδευσης σε 20,000. Αυτό περιορίσε την πληρότητα της εκπαίδευσης και την επίτευξη πλήρους σύγκλισης του μοντέλου. Παρ' όλα αυτά, οι αποδόσεις που παρουσιάστηκαν ήταν ενθαρρυντικές και δείχνουν τη δυνατότητα για περαιτέρω βελτιώσεις με την εφαρμογή κατάλληλων τεχνικών για τη διαχείριση των τεχνικών προκλήσεων.

Προτείνουμε επομένως την επέκταση της ποικιλίας των δεδομένων με νέα δείγματα από διαφορετικές περιοχές και καλλιέργειες, προκειμένου να βελτιωθεί η γενίκευση του μοντέλου. Επίσης, προτείνουμε τη χρήση πιο προηγμένων αλγορίθμων μηχανικής μάθησης ή τον συνδυασμό διαφορετικών τύπων νευρωνικών δικτύων για ακόμα καλύτερη απόδοση. Τέλος, προτείνουμε την ανάπτυξη εργαλείων που θα διευκολύνουν την εύκολη και αποτελεσματική εφαρμογή της τεχνολογίας στην καθημερινή αγροτική πρακτική. Η έρευνα αυτή υπογραμμίζει τη σημασία της τεχνολογίας στη γεωργία και πώς η μηχανική μάθηση μπορεί να συμβάλει στη βελτίωση της αγροτικής παραγωγικότητας και βιωσιμότητας.



5. Βιβλιογραφία

- [1] Z. Zou, K. Chen, Z. Shi, Y. Guo, and J. Ye, “Object Detection in 20 Years: A Survey,” May 2019, [Online]. Available: <http://arxiv.org/abs/1905.05055>
- [2] S. Agatonovic-Kustrin and R. Beresford, “Basic concepts of artificial neural network (ANN) modeling and its application in pharmaceutical research,” 2000. [Online]. Available: www.elsevier.com/locate/jpba
- [3] K. O’Shea and R. Nash, “An Introduction to Convolutional Neural Networks,” Nov. 2015, [Online]. Available: <http://arxiv.org/abs/1511.08458>
- [4] S. B. Maind and P. Wankar, “International Journal on Recent and Innovation Trends in Computing and Communication Research Paper on Basic of Artificial Neural Network”, [Online]. Available: <http://www.ijritcc.org>
- [5] T. Kattenborn, J. Leitloff, F. Schiefer, and S. Hinz, “Review on Convolutional Neural Networks (CNN) in vegetation remote sensing,” *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 173. Elsevier B.V., pp. 24–49, Mar. 01, 2021. doi: 10.1016/j.isprsjprs.2020.12.010.
- [6] M. Carranza-García, J. Torres-Mateo, P. Lara-Benítez, and J. García-Gutiérrez, “On the performance of one-stage and two-stage object detectors in autonomous vehicles using camera data,” *Remote Sens (Basel)*, vol. 13, no. 1, pp. 1–23, Jan. 2021, doi: 10.3390/rs13010089.
- [7] K. Chen *et al.*, “Towards Accurate One-Stage Object Detection with AP-Loss.”
- [8] X. Lu, Q. Li, B. Li, and J. Yan, “MimicDet: Bridging the Gap Between One-Stage and Two-Stage Object Detection,” Sep. 2020, [Online]. Available: <http://arxiv.org/abs/2009.11528>
- [9] L. Du, R. Zhang, and X. Wang, “Overview of two-stage object detection algorithms,” in *Journal of Physics: Conference Series*, Institute of Physics Publishing, Jun. 2020. doi: 10.1088/1742-6596/1544/1/012033.
- [10] R. Padilla, S. L. Netto, E. A. B. Da Silva, and S. L. Netto, “A Survey on Performance Metrics for Object-Detection Algorithms”, doi: 10.1109/IWSSIP48289.2020.
- [11] C. Sullca, C. Molina, C. Rodríguez, and T. Fernández, “Diseases detection in blueberry leaves using computer vision and machine learning techniques,” *Int J Mach Learn Comput*, vol. 9, no. 5, pp. 656–661, Sep. 2019, doi: 10.18178/ijmlc.2019.9.5.854.